LAPORAN PROYEK UJIAN TENGAH SEMESTER

MATA KULIAH PEMBELAJARAN MESIN

PREDIKSI HARGA RUMAH MENGGUNAKAN METODE SIMPLE DAN MULTIPLE LINEAR REGRESSION

Disusun Oleh:

Exeldus Moreno/2301020074

Dosen Pengampu:

IDA BAGUS KRESNA SUDIATMIKA, S.KOM., M.T.

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNOLOGI INFORMASI DAN DESAIN

PRIMAKARA UNIVERSITY

TAHUN AJARAN 2025/2026

1. Latar Belakang

Penentuan harga rumah merupakan permasalahan yang kompleks dalam bidang properti karena dipengaruhi oleh berbagai faktor seperti luas bangunan, jumlah kamar, lokasi, dan tahun pembangunan. Dalam praktiknya, penentuan harga sering kali dilakukan secara subjektif berdasarkan perkiraan atau pengalaman, sehingga berpotensi menghasilkan nilai yang kurang akurat.

Dengan adanya data historis yang tersedia, pendekatan berbasis data dapat digunakan untuk membantu memahami hubungan antara karakteristik rumah dengan harga jualnya. Salah satu metode yang dapat digunakan adalah Machine Learning, khususnya algoritma regresi, yang mampu memodelkan hubungan antara variabel input (fitur) dan output (harga).

Pada proyek ini, digunakan metode Simple Linear Regression dan Multiple Linear Regression untuk memprediksi harga rumah berdasarkan dataset yang diperoleh dari Kaggle. Dengan membandingkan kedua pendekatan tersebut, diharapkan dapat diketahui seberapa besar pengaruh penggunaan jumlah fitur terhadap akurasi model dalam melakukan prediksi.

2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah dalam proyek ini adalah:

- Bagaimana cara memprediksi harga rumah menggunakan metode regresi linear?
- Seberapa besar pengaruh fitur seperti luas bangunan, jumlah kamar, lokasi, dan umur bangunan terhadap harga rumah?
- Apakah Multiple Linear Regression memberikan hasil yang lebih baik dibandingkan Simple Linear Regression?

3. Metodologi

Dataset

Dataset yang digunakan dalam penelitian ini berasal dari Kaggle dan terdiri dari sekitar 50.000 data rumah. Dataset ini memuat beberapa fitur yang relevan dalam menentukan harga rumah, yaitu:

- SquareFeet (luas bangunan)
- Bedrooms (jumlah kamar tidur)
- Bathrooms (jumlah kamar mandi)
- Neighborhood (lokasi rumah)
- YearBuilt (tahun pembangunan)
- Price (harga rumah sebagai variabel target)

Dataset ini dipilih karena memiliki jumlah data yang cukup besar serta fitur yang representatif untuk memodelkan harga rumah.

Exploratory Data Analysis (EDA)

Tahap awal dilakukan Exploratory Data Analysis (EDA) untuk memahami karakteristik data. Analisis yang dilakukan meliputi:

- Statistik deskriptif untuk mengetahui distribusi dan rentang data
- Visualisasi distribusi harga rumah untuk melihat pola sebaran data
- Deteksi outlier menggunakan boxplot
- Analisis korelasi antar fitur menggunakan heatmap

Tahap ini bertujuan untuk mengidentifikasi pola, hubungan antar variabel, serta potensi masalah pada data sebelum dilakukan pemodelan.

Data Preprocessing

Pada tahap ini dilakukan persiapan data agar dapat digunakan oleh model Machine Learning. Langkah-langkah yang dilakukan meliputi:

- Pengecekan missing value untuk memastikan tidak terdapat data kosong
- Encoding variabel kategorikal (Neighborhood) menggunakan One-Hot Encoding agar dapat diproses oleh model
- Feature scaling menggunakan StandardScaler untuk menyamakan skala antar fitur numerik

Tahap preprocessing penting untuk memastikan data berada dalam kondisi yang optimal sebelum digunakan dalam proses training model.

Feature Engineering

Dilakukan pembuatan fitur baru untuk meningkatkan kualitas model, yaitu:

- age (umur bangunan), yang dihitung dari selisih antara tahun saat ini dengan YearBuilt

Fitur ini ditambahkan karena umur bangunan dianggap lebih representatif dibandingkan tahun pembangunan dalam mempengaruhi harga rumah.

Pemodelan

Pada tahap ini digunakan dua pendekatan model regresi, yaitu:

1. **Simple Linear Regression**

   Model ini menggunakan satu fitur yaitu SquareFeet untuk memprediksi harga rumah. Model ini digunakan sebagai baseline untuk melihat hubungan sederhana antara luas bangunan dan harga.

2. **Multiple Linear Regression**

Model ini menggunakan seluruh fitur yang tersedia, termasuk fitur hasil encoding dan feature engineering. Tujuannya adalah untuk meningkatkan akurasi prediksi dengan mempertimbangkan lebih banyak variabel yang berpengaruh.

Selain itu, dataset dibagi menjadi data training dan data testing dengan rasio 80:20 menggunakan metode train-test split untuk memastikan model dapat dievaluasi secara objektif terhadap data yang belum pernah dilihat sebelumnya.

4. Hasil Exploratory Data Analysis (EDA)

Berdasarkan hasil analisis data yang telah dilakukan, diperoleh beberapa temuan penting sebagai berikut:

Distribusi harga rumah menunjukkan pola yang mendekati distribusi normal, namun terdapat beberapa nilai ekstrem (outlier) dengan harga yang jauh lebih tinggi dibandingkan mayoritas data. Hal ini mengindikasikan adanya variasi harga yang cukup besar dalam dataset, kemungkinan dipengaruhi oleh faktor lokasi atau spesifikasi rumah tertentu.

Hasil analisis korelasi menunjukkan bahwa fitur SquareFeet memiliki hubungan yang paling kuat terhadap harga rumah. Hal ini menunjukkan bahwa luas bangunan merupakan faktor utama dalam menentukan harga, di mana semakin besar luas bangunan, maka harga rumah cenderung semakin tinggi.

Selain itu, fitur lain seperti jumlah kamar (Bedrooms dan Bathrooms) serta lokasi (Neighborhood) juga memiliki pengaruh terhadap harga, meskipun tingkat korelasinya tidak sekuat luas bangunan. Hal ini menunjukkan bahwa harga rumah tidak hanya dipengaruhi oleh satu faktor, tetapi merupakan kombinasi dari beberapa variabel.

Dari hasil pengecekan data, tidak ditemukan missing value pada seluruh fitur, sehingga dataset berada dalam kondisi bersih dan siap digunakan untuk tahap preprocessing dan pemodelan tanpa perlu penanganan data kosong.

Secara keseluruhan, hasil EDA menunjukkan bahwa dataset memiliki kualitas yang baik dan terdapat hubungan yang cukup jelas antar variabel, sehingga layak untuk digunakan dalam pembangunan model prediksi harga rumah.

5. Hasil Pemodelan

Simple Linear Regression

Pada tahap ini digunakan model Simple Linear Regression dengan satu fitur yaitu SquareFeet. Model ini bertujuan untuk melihat hubungan sederhana antara luas bangunan dengan harga rumah.

Berdasarkan hasil evaluasi model, diperoleh:

- MAE = 39675.18
- RMSE = 49661.78
- $R^2 = 0.57$

Nilai R^2 sebesar 0.57 menunjukkan bahwa model hanya mampu menjelaskan sekitar 57% variasi harga rumah. Sementara itu, nilai MAE dan RMSE yang cukup besar menunjukkan bahwa masih terdapat selisih yang signifikan antara nilai prediksi dan nilai aktual.

Hal ini menunjukkan bahwa meskipun luas bangunan memiliki pengaruh terhadap harga, penggunaan satu fitur saja belum cukup untuk menghasilkan prediksi yang akurat.

Multiple Linear Regression

Selanjutnya digunakan model Multiple Linear Regression dengan memanfaatkan seluruh fitur yang tersedia, termasuk hasil encoding dan feature engineering.

Hasil evaluasi menunjukkan bahwa model ini memiliki performa yang lebih baik dibandingkan Simple Linear Regression, yang ditunjukkan dengan nilai R^2 yang lebih tinggi serta nilai error yang lebih rendah.

Hal ini terjadi karena model mampu mempertimbangkan berbagai faktor seperti jumlah kamar, lokasi, dan umur bangunan, sehingga hubungan yang lebih kompleks antar variabel dapat ditangkap dengan lebih baik.

Perbandingan Model

Berdasarkan hasil evaluasi kedua model:

- Simple Linear Regression hanya mampu menjelaskan sebagian variasi data ($R^2 = 0.57$)
- Multiple Linear Regression menunjukkan performa yang lebih baik dengan kemampuan prediksi yang lebih tinggi
- Nilai error pada Multiple Linear Regression lebih kecil dibandingkan Simple Linear Regression

Dengan demikian, dapat disimpulkan bahwa Multiple Linear Regression lebih efektif dalam memprediksi harga rumah karena mampu memanfaatkan lebih banyak informasi dari berbagai fitur yang tersedia.

6. Analisis Error

Evaluasi model dilakukan untuk mengukur seberapa baik model dalam memprediksi harga rumah menggunakan beberapa metrik, yaitu MAE, RMSE, dan R^2 Score.

- MAE (Mean Absolute Error) digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. Nilai ini memberikan gambaran seberapa besar kesalahan prediksi secara umum.
- RMSE (Root Mean Squared Error) digunakan untuk mengukur error dengan memberikan penalti lebih besar terhadap kesalahan yang besar, sehingga metrik ini sensitif terhadap outlier.
- R^2 Score (Coefficient of Determination) digunakan untuk mengetahui seberapa besar variasi data yang dapat dijelaskan oleh model.

Hasil Evaluasi

Berdasarkan hasil yang diperoleh:

- Model Multiple Linear Regression memiliki nilai MAE dan RMSE yang lebih rendah dibandingkan Simple Linear Regression, yang menunjukkan bahwa kesalahan prediksi model lebih kecil.
- Nilai R^2 pada Multiple Linear Regression juga lebih tinggi, yang menunjukkan bahwa model mampu menjelaskan variasi harga rumah dengan lebih baik.

Hal ini mengindikasikan bahwa penggunaan lebih banyak fitur memberikan informasi tambahan yang signifikan dalam meningkatkan performa model.

Analisis Residual

Analisis residual dilakukan untuk mengevaluasi pola kesalahan prediksi model. Berdasarkan residual plot yang telah ditampilkan:

- Residual tersebar di sekitar garis nol tanpa membentuk pola tertentu yang jelas
- Tidak ditemukan pola sistematis seperti kurva atau tren tertentu
- Hal ini menunjukkan bahwa model sudah cukup memenuhi asumsi dasar regresi linear

Namun, penyebaran residual masih cukup lebar, yang menunjukkan bahwa terdapat variasi error yang cukup besar pada beberapa data.

Interpretasi

Berdasarkan hasil evaluasi dan analisis residual, dapat disimpulkan bahwa model Multiple Linear Regression sudah mampu menangkap pola hubungan antar variabel dengan cukup baik, namun belum sepenuhnya optimal.

Hal ini kemungkinan disebabkan oleh:

- adanya faktor lain yang belum dimasukkan ke dalam model
- keberadaan outlier yang mempengaruhi nilai error
- keterbatasan model linear dalam menangkap hubungan yang lebih kompleks

Dengan demikian, meskipun model sudah cukup baik untuk digunakan sebagai prediksi awal, masih diperlukan pengembangan lebih lanjut untuk meningkatkan akurasi model.

7. Kesimpulan

Berdasarkan seluruh tahapan yang telah dilakukan, mulai dari Exploratory Data Analysis (EDA), preprocessing, hingga pemodelan dan evaluasi, dapat disimpulkan bahwa metode Machine Learning khususnya Linear Regression dapat digunakan untuk memprediksi harga rumah dengan cukup baik.

Hasil analisis menunjukkan bahwa fitur seperti luas bangunan (SquareFeet), lokasi (Neighborhood), serta jumlah kamar memiliki pengaruh terhadap harga rumah. Di antara fitur tersebut, luas bangunan memiliki hubungan yang paling kuat terhadap harga, sehingga menjadi faktor utama dalam proses prediksi.

Dari hasil pemodelan, Multiple Linear Regression memberikan performa yang lebih baik dibandingkan Simple Linear Regression. Hal ini ditunjukkan oleh nilai R^2 yang lebih tinggi serta nilai error (MAE dan RMSE) yang lebih rendah, yang menandakan bahwa model mampu memanfaatkan lebih banyak informasi dari berbagai fitur untuk meningkatkan akurasi prediksi.

Namun demikian, model yang dibangun masih memiliki keterbatasan, yang terlihat dari masih adanya error yang cukup besar pada hasil prediksi. Hal ini menunjukkan bahwa masih terdapat faktor lain di luar dataset yang belum dimasukkan ke dalam model, serta kemungkinan adanya hubungan non-linear yang tidak dapat ditangkap oleh model linear.

Dengan demikian, untuk pengembangan lebih lanjut, model dapat ditingkatkan dengan menambahkan fitur yang lebih relevan, menangani outlier secara lebih optimal, serta mencoba algoritma yang lebih kompleks agar hasil prediksi menjadi lebih akurat.

8. Referensi

Berikut adalah sumber referensi yang digunakan dalam pengerjaan proyek ini:

1. Kaggle. *Housing Price Dataset*.

   Tersedia pada:

   https://www.kaggle.com/datasets/muhammadbinimran/housing-price-prediction-data
   (diakses pada April 2026)

2. Scikit-learn. *Linear Regression Documentation*.

   Tersedia pada:

3. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html
   (diakses pada April 2026)

4. Pandas. *Pandas Documentation*.

   Tersedia pada:

   https://pandas.pydata.org/docs/
   (diakses pada April 2026)

5. Seaborn. *Seaborn Statistical Data Visualization*.

   Tersedia pada:

   https://seaborn.pydata.org/
   (diakses pada April 2026)

6. NumPy. *NumPy Documentation*.

   Tersedia pada:

https://numpy.org/doc/
(diakses pada April 2026)

7. Matplotlib. *Matplotlib Documentation*.

Tersedia pada:

https://matplotlib.org/stable/contents.html
(diakses pada April 2026)